



# Aprendizagem 2021/22 Homework I – Group 117


## I. Pen-and-paper

#### Answer 1





Cluster 2



```
12= -1) | Para C=11
                   → prior: P(c=1) = 0.7

→ likelihood: P(X|C=1) = 2,239X10^{-13}

→ joint probability = 4,567 X10<sup>-13</sup>
                 Para C=21
                     - prior P(C=2)=0,3
- likelihood P(XIC=2)=0,0796
                     - joint probability = 0,0239
  NORHALIZAR
               C=1 P (C=1/2) = 0
               C=2 : P(C=2122)=1
  23=[-1] | Para C=1
                → prior: P(C=1)=0,7

→ likelihosel: P(x1C=1)=0,00024

→ joint probability=0,00017
               Para C=2
                 - prior: P(C=2)=0,3
- ardihood: P(X(C=2)=9,8206x10-6
 - joint probability=2,9462×10-6
        C=1: P(C=1/N3) = 9,9227
C=2: P(C=2/N3) = 0,0173
                  - prior: P(C=1)=0,7
- likelihood: P(XIC=1)=7,226×10-6
            - joint probability= 5,058x 10-6

| Para C=2|
- prior P(C=2)=0,3
- Pikelihood. P(x1C=2)=2,814x10-6
- joint probability= 8,441x10-7
NORMALIZAR
          C=1. P (C=1124) =0,8570
          C=2 P(C=2124)=0,143
```

```
U1= 1x(2)+0,4821 [-1]+0,852[4] = [1,5564]
                                                     1+0,9827+0,857
              Z_n = \frac{1(2-1,5654)^2 + 0(-1-1,5654)^2 + 0.9827(-1-1,5634)^2 + 0.857(4-1,5634)^2}{1(2-1,5654)^2 + 0.857(4-1,5634)^2}
                              = 4,1328

Σα= ξ<sub>21</sub> = 1x(2-1,5654) (4-2,1004)+0x(-1-1,5654) (4-2,1004)+09917+(-1-1,5654)(2-2,1004)

                                                                                                                                                                                                              + 0,857 (4-1,5654) (0-2,0007)
                                                                                                                   1+0+0,9827+0,857
                              =-1,1634
            Z_{22} = \frac{1}{4}x(4-2,1007)^2 + 0(-4-2,1007)^2 + 0.0322(2-2,1007)^2 + 0.357(0-2,1007)^2
                     = 2,6056
              P(X|C=1) = N\left(y, = \begin{bmatrix} 1,5654 \\ 2,1007 \end{bmatrix}, \Sigma_1 = \begin{bmatrix} 4,1328 & -1,1634 \\ -1,1634 & 2,60561 \end{bmatrix}\right)
                       Z11= 0(210,3838)2+1(-1+0,3832)2+0,0173(-1+0,3832)2+0,143(4+0,3838)2
                        = 1,1038
       \mathcal{L}_{12} = \mathcal{Z}_{21} = O(2+0.3332)(4+3,4174) + 1(-1+0.3332)(-413,4476) + 0.013(-1+0.3238)(2+3,1476)
                                                                                                                                                                                      +9143 (4+03838) (013,1476)
    E22 = 0(4+3,4176)2+1x(4-3,4176)2+0,0173(2+3,4176)2+0,143(0+3,4176)2
P(X|C=2) = N \quad |y_2| = \frac{-9.8838}{-3.4120}, \quad Z_2 = \frac{1}{1038} \quad 0.8605
P(C=1) = P(C=1|X_1) + P(C=1|X_2) + P(C=1|X_3) + P(C=1|X_4)
                        P(C=1/21)+P(C=1/22)+P(C=1/21)+P(C=1/22)+P(C=2/21)+P(C=2/22)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/23)+P(C=2/
                           = 0,710
P(C=0) = 1-P(C=1)=0,290
```




#### Homework I - Group 117

#### Answer 2

```
2- Knj Kze Ku E Clustor 1
Kz E Cluster 2
       Silhauette para XI
        \alpha(\mathcal{H}_1) = \frac{1}{2} \left( \| \mathbf{x}_1 - \mathbf{x}_3 \|_2 + \| \mathbf{x}_1 - \mathbf{x}_4 \|_2 \right) = \frac{1}{3} (\sqrt{(2+1)^2} \mathbf{1} (\mathbf{u} - 2)^2 + \sqrt{(2-\mathbf{u})^2} \mathbf{1} (\mathbf{u} - 0)^2 \right) = 4\sqrt{3}
        6(x1) = 1/21-2211, = \((2+1)^2 + (4+4)^2 = 8)544
       S(ki) = 1- a(ki) = 1-4039 = 0,527
     Thanette para 1/2
        6(1/2) = 1/3 (11/2-4/11/2 4/11/2-43/1/4/11/2)=6,982
    Silhauette para uz
        a(213) = 1 (1123-211/2+1123-261/2)=4,495
        b(213) = 10/3-76=112=6
        S(n) = 1 - \frac{a(n_3)}{b(n_3)} = 1 - \frac{4,495}{6} = 0,251
   Silhauette para 24 (1124-1131/2)=4,929
        b(24) = 124-22/12 = 6,403
        S(24) = 1- a(24) = 0,230
 Silhauette de ci
        S(C1) = S(X1) + S(X1) + S(X4) = 0,527+0,251+0,230 =0,336
Silhauette de Cz
       S(C2) = S(N2) = 1=1
Silhauette de C
                 5(c) = 5(c) + 5(c2) = 0,336+1 = 0,668
```

# Answer 3-a

i-



```
11 /1 /1 2

0 00 000 000

3 6 9 12 15 16 21 2427
```




## Homework I - Group 117




$$N(\mu, z) = 1 - P(c=1) - 1$$
 parametro  $Z = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 2 & 3 & 4 & 5 \end{bmatrix}$  parametros  $Z = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 2 & 3 & 4 & 5 \end{bmatrix}$  parametros  $Z = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 2 & 3 & 4 & 5 \\ 2 & 3 & 3 & 3 \end{bmatrix}$ 

## Answer 3-b



Pela observação do gráfico, verifica-se que a variação da vcDimension da decision tree (ii), aumenta exponencialmente, e verifica-se um aumento abrupto a partir de data dimensionality = 10 face à MLP com 3 hidden layers e ao Bayesian Classifier com uma multivariate Gaussian likelihood.

#### Answer 3-c




Pela observação do gráfico, verifica-se que um maior aumento da vcDimension no MLP Classifier com 3 hidden layers do que no Bayesian Classifier com uma multivariate Gaussian likelihood a partir da data dimensionality = 100.



# Aprendizagem 2021/22 Homework I – Group 117

## II. Programming and critical analysis

### Answer 4



Silhouette K = 2 0.5967981179111456 Silhouette K = 3 0.5245427800706391

a)


Pelos resultados acima apresentados verifica-se que no algoritmo k Me<br/>ans, k=3 apresenta um melhor ECR value que k=2 para a nossa data.

Sendo o ECR a média dos pontos mal classificados concluimos que ao adicionarmos um novo cluster vai existir uma maior margem para classificação de pontos, e portanto menos pontos mal classificados, assim é natural que o ECR seja mais pequeno para k = 3.

**b**)

Pelos resultados acima apresentados verifica-se que no algoritmo k Means, k=2 apresenta uma melhor silhouette que k=3 para a nossa data. Isto deve-se ao facto de para k=2 os clusters serem mais compactos e estarem mais separados entre si.

#### Answer 5





# Aprendizagem 2021/22 Homework I – Group 117

#### Answer 6

No exercício 5 verifica-se que a silhouette do algoritmo k Means com k=2 e apenas selecionando as 2 melhores features da nossa data segundo a mutual information é bastante boa, isto significa que os cluster são compactos e estão afastados entre si, algo que se pode verificar pelo gráfico apresentado na resposta 5.

Quanto ao ECR value verifica-se que este é melhor do que para k=2 usando toda a data, mas pior do que para k=3 usando toda a data.

Sendo o ECR a média dos pontos mal classificados concluimos que ao adicionarmos um novo cluster vai existir uma maior margem para classificação de pontos, e portanto menos pontos mal classificados, assim é natural que o ECR seja mais pequeno do que para k=2. Dado que no exercício 5 apenas se selecionam as duas melhores features, a nossa data torna-se mais imprecisa o que leva a um maior grupo de pontos mal classificados, portanto é normal que o ECR value do exercício 5 seja maior que o de k=3.



## Homework I - Group 117

#### III. APPENDIX

Paste your programming code here using Consolas 9pt or 10pt.
Use highlighting or colored text to facilitate the analysis by your faculty hosts.

```
# Grupo 117 Aprendizagem HomeWork 4
# Bernardo Castico ist196845
# Hugo Rita ist196870
import pandas as pd
import sklearn
from scipy.io import arff
from sklearn.cluster import KMeans
import numpy as np
from sklearn.metrics import silhouette_score
from sklearn.feature_selection import SelectKBest
from sklearn.feature_selection import mutual_info_classif
import matplotlib.pyplot as plt
def getDataToMatrix(lines):
   realLines = []
   data = []
   toDelete = []
   for i in range(len(lines)):
        if i > 11:
            realLines += [lines[i]]
   for i in range(len(realLines)):
        for j in range(len(realLines[i])):
            if realLines[i][j] == "benign\n":
                realLines[i][j] = "benign"
            elif realLines[i][j] == "malignant\n":
                realLines[i][j] = "malignant"
            elif realLines[i][j] == '?':
                toDelete += [i]
                realLines[i][j] = int(realLines[i][j])
    for i in range(len(realLines)):
        if i not in toDelete:
            data += [realLines[i]]
    return data
def splitData(list):
   a = []
   b = []
    for i in list:
      a.append(i[:-1])
```



## Homework I - Group 117

```
b.append(i[-1])
   return [a,b]
def main():
   data, res2 = [],[]
   cluster02, cluster12, cluster03, cluster13, cluster23, cluster05, cluster15, cluster25 =
0,0,0,0,0,0,0,0
   Benign02, malignant02, Benign12, malignant12, Benign03, malignant03, Benign13, malignant13,
Benign23, malignant23 = 0,0,0,0,0,0,0,0,0,0,0
   Benign05, malignant05, Benign15, malignant15, Benign25, malignant25 = 0,0,0,0,0,0
   xCluster0, yCluster0, xCluster1, yCluster1, xCluster2, yCluster2 = [],[],[],[],[]
   with open("HW3-breast.txt") as f:
       lines = f.readlines()
   for line in lines:
       tmp = line.split(',')
       res2.append(tmp)
   data = getDataToMatrix(res2)
   trainDataSplit = splitData(data)
   kMeans2 = KMeans(n_clusters=2, random_state=0).fit(trainDataSplit[0])
   kMeans3 = KMeans(n_clusters=3, random_state=0).fit(trainDataSplit[0])
   kLabels2 = kMeans2.labels_
   kLabels3 = kMeans3.labels_
   for i in range(len(kLabels2)):
       if kLabels2[i] == 0:
           cluster02 += 1
           if trainDataSplit[1][i] == 'malignant':
                malignant02 += 1
                Benign02 += 1
       elif kLabels2[i] == 1:
           cluster12 += 1
           if trainDataSplit[1][i] == 'malignant':
                malignant12 += 1
           else:
                Benign12 += 1
       if kLabels3[i] == 0:
           cluster03 += 1
           if trainDataSplit[1][i] == 'malignant':
               malignant03 += 1
                Benign03 += 1
       elif kLabels3[i] == 1:
           cluster13 += 1
```



### Homework I - Group 117

```
if trainDataSplit[1][i] == 'malignant':
               malignant13 += 1
               Benign13 += 1
       elif kLabels3[i] == 2:
           cluster23 += 1
           if trainDataSplit[1][i] == 'malignant':
               malignant23 += 1
               Benign23 += 1
   ECR2 = 0.5*((cluster02-max(Benign02,malignant02)) + (cluster12-max(Benign12, malignant12)))
   ECR3 = (1/3)*((cluster03-max(Benign03,malignant03)) + (cluster13-max(Benign13, malignant13))+
(cluster23-max(Benign23, malignant23)))
   print("ECR K = 2")
   print(ECR2)
   print("ECR k = 3")
   print(ECR3)
   print("Silhouette K = 2")
   print(silhouette_score(trainDataSplit[0], kLabels2))
   print("Silhouette K = 3")
   print(silhouette_score(trainDataSplit[0], kLabels3))
   decision = SelectKBest(mutual_info_classif, k=2).fit(trainDataSplit[0], trainDataSplit[1])
   decisionTrainData = decision.transform(trainDataSplit[0])
   kMeans3Ex5 = KMeans(n_clusters=3, random_state=0).fit(decisionTrainData)
   kLabelsEx5 = kMeans3Ex5.labels_
   for i in range(len(kLabelsEx5)):
       if kLabelsEx5[i] == 0:
           cluster05 += 1
           if trainDataSplit[1][i] == 'malignant':
               malignant05 += 1
           else:
               Benign05 += 1
       elif kLabelsEx5[i] == 1:
           cluster15 += 1
           if trainDataSplit[1][i] == 'malignant':
               malignant15 += 1
               Benign15 += 1
       elif kLabelsEx5[i] == 2:
           cluster25 += 1
```



## Homework I - Group 117

```
if trainDataSplit[1][i] == 'malignant':
                malignant25 += 1
                Benign25 += 1
   ECR5 = (1/3)*((cluster05-max(Benign05,malignant05)) + (cluster15-max(Benign15, malignant15))+
(cluster25-max(Benign25, malignant25)))
   print("ECR Ex5")
   print(ECR5)
   print("Silhouette Ex5")
   print(silhouette_score(decisionTrainData, kLabelsEx5))
   for i in range(len(kLabelsEx5)):
       if kLabelsEx5[i] == 0:
           xCluster0 += [decisionTrainData[i][0]]
           yCluster0 += [decisionTrainData[i][1]]
       elif kLabelsEx5[i] == 1:
           xCluster1 += [decisionTrainData[i][0]]
           yCluster1 += [decisionTrainData[i][1]]
           xCluster2 += [decisionTrainData[i][0]]
           yCluster2 += [decisionTrainData[i][1]]
   plt.scatter(xCluster0, yCluster0, label="Cluster 0")
   plt.scatter(xCluster1, yCluster1, label="Cluster 1")
   plt.scatter(xCluster2, yCluster2, label="Cluster 2")
   plt.xlabel('x - BestFeature1')
   plt.ylabel('y - BestFeature2')
   plt.title('Cluster solution with k=3 and 2 K best features')
   plt.legend()
   plt.show()
main()
```